Refonte du prompt de génération : choix, justifications et énoncés d'appui

Document de travail pour le projet « règles de l'absurde ». Fait suite au document de définitions du 11 novembre 2026 (schéma repris : définition, usages, tableau de références) et à l'annotation d'un jeu de 117 énoncés générés par des modèles, commentés ligne à ligne (fichier annotation_Charles.xlsx ; « id » = numéro de ligne de la feuille Annotation).

Statut des références. ✓ = notice déjà consultée en ligne dans le document du 11 novembre (titre, auteurs, venue conformes). ○ = référence citée de mémoire, notice **non consultée**, à vérifier avant citation. Aucune formulation d'auteur n'est citée entre guillemets : les apports sont des paraphrases. **Limite.** Un seul annotateur, 117 énoncés : les listes d'ids ci-dessous sont des constats descriptifs, pas des effets mesurés. La refonte est une hypothèse, à tester par ablation (section 4).

1. Diagnostic de la version 1

24 énoncés sur 117 sont « tout au vert » ; pour 11 d'entre eux (ids 7, 8, 16, 38, 42, 46, 58, 98, 100, 110, 111) l'annotateur écrit que ça rate ou ne marche qu'à moitié. Les cinq critères de la procédure (cadre, résolution, règle, consistance, attributs) sont nécessaires mais ne distinguent pas l'absurde qui fonctionne du reste. Les cas jugés réussis sont rares : ids 14, 114, 43, 85, 84. Les échecs se regroupent en trois familles : règle inventée qui bascule dans le fantastique, norme sans enjeu, énoncé qui désamorce ou commente sa propre friction.

2. Définition révisée

Absurde hyperlogique (version concise révisée). Un énoncé situé dans le monde ordinaire est hyperlogique lorsqu'il applique à la lettre une règle explicite R, qui existe ou pourrait exister dans nos institutions, notre langue ou nos conventions, et dont la conséquence C viole une norme fondamentale N que ni R ni le cadre générique du texte ne suspend, l'ensemble {R, C} restant consistant et le texte n'expliquant ni ne commentant l'incompatibilité.

Ce qui change par rapport à la version du 11 novembre.

- D1-D3 inchangés, mais D3 couvre aussi le *commentaire* de l'étrangeté, pas seulement la résolution.
- Nouveau D4 · Monde ordinaire : tous les faits de l'énoncé sont possibles dans le monde actuel une fois R admise comme règle humaine.
- Nouveau D5 · Enjeu : N est une norme dont la violation touche une valeur (justice, identité, mort, propriété, autorité, vérité, soin), pas une simple habitude pratique.
- Consistance : nécessaire mais plus suffisante ; P3 devient « monde ordinaire où R et C sont vrais ensemble ».
- Rigueur : valide par défaut dans la cellule cible ; le sophisme assumé par le texte (cas Ionesco) devient une cellule distincte.

Procédure d'annotation révisée (la colonne P actuelle, « hors cadre / involontaire », est conservée comme voie de sortie analysable, non jetée).

Étape	Question posée à l'annotateur	Issue
1a Cadre	Peut-on écrire « on s'attendrait à ce que… » en nommant le cadre heurté ?	Non → hors corpus
1b Non résolu, non commenté	Le texte lève-t-il l'incompatibilité, l'explique-t-il, ou commente-t-il l'étrangeté de la règle ou de sa conséquence ?	Oui → hors corpus (désamorçage)
1c Monde ordinaire (nouveau)	R admise comme règle humaine, tous les faits sont-ils possibles dans le monde actuel ? (magie, loi physique modifiée, invisibilité, duplication, animal qui parle = non)	Non → hors monde ordinaire
2a Règle	R tient-elle en une phrase, existe-t-elle ou pourrait-elle exister dans nos institutions, et est-elle énoncée comme texte du monde (plaque, règlement) ou reconstituable depuis les faits ?	Introuvable → P1 ; inventée → hors monde ordinaire
2b Consistance	Peut-on imaginer ce monde ordinaire où R et C sont vrais ensemble ?	Non → P2
2c Enjeu (nouveau)	La violation de N touche-t-elle une valeur, ou n'est-ce qu'un paradoxe banal, une curiosité ?	Non → hors corpus (sans friction)
3 Attributs	Rigueur (valide / sophistique assumé / erreur), intérêt local, productivité, **fidélité interne** (nouveau : R appliquée de façon constante), intentionnalité, fonction.	Aucune exclusion
Rejets nommés	Si hors corpus, coder le motif : métaphore, énigme, vérité banale, paradoxe banal, erreur, dénonciation, hors monde ordinaire, trop expliqué.	Alimente le diagnostic

3. Choix de conception du prompt et justifications

Chaque ligne relie un choix de la version 2 (section 4) à son appui dans l'état de l'art et aux énoncés annotés qui l'ont motivé. Les références sont détaillées section 6.

Choix	Justification (état de l'art)	Énoncés d'appui (ids)
C1 Monde ordinaire (contrainte 1)	Dans le fantastique, c'est le contrat de genre qui suspend N : le lecteur a consenti à la violation, donc pas de friction (Coleridge ○ ; Todorov ○ ; Jackson ○). La consistance seule ne suffit pas : R doit être accessible depuis le monde réel (Ryan ○ ; Lewis ○).	Écartés par l'annotateur (« fantastique », « merveilleux », « SF ») : 1, 31, 33, 35, 44, 83, 92, 99, 107, 110, 111. Contre-exemples conservés : 14, 114.
C2 R existe dans nos institutions (champ R)	L'application littérale d'une règle réelle est le ressort de l'absurde bureaucratique (Kafka ○). Les règles ont une texture ouverte (Hart ○) et suivre une règle fait problème en soi (Kripke ○ ; Carroll 1895 ○). Bergson ○ : du mécanique plaqué sur du vivant. Gattegno ○ : validité sans souci d'existence.	Règles institutionnelles retenues : 12 (compte rendu), 14 (objets trouvés), 38 (club d'échecs), 100 (caution), 109 (serment), 114. Règles inventées jugées sans friction : 29, 30, 31, 32, 49, 54, 57, 65, 66, 69, 75, 81, 82, 83, 95, 97.
C3 N fondamentale, avec enjeu (champ N)	Nagel ✓ : l'absurde naît de la collision entre le sérieux de nos engagements et leur possible arbitraire. McGraw & Warren ○ : la violation doit toucher une norme qui compte tout en restant bénigne. Brewer & Lichtenstein ○ : la tension narrative suppose un enjeu.	Sans friction faute d'enjeu : 32, 91, 98, 106. « Paradoxe banal, aucun enjeu moral » : 108, 112, 117. Tension kafkaïenne recherchée : 12, 100, 109 ; 16 « pas assez de tension ».
C4 Ne rien expliquer ni commenter ; aucun texte hors des champs (contraintes 4 et 10)	Incongruité-résolution (Suls ○ ; Raskin ○) : expliquer ou résoudre ramène au normal. La règle peut figurer comme texte du monde ; c'est le commentaire de son étrangeté qui désamorce. Les formats imposés peuvent dégrader la production (Tam et al. ○) : on sépare le texte de toute auto-évaluation.	Énoncé qui nomme la friction ou sur-explique : 37, 41, 50, 68, 73, 82, 90, 98. Blocs « Détails des contraintes » ou « Note » ajoutés : 7, 13, 16, 31, 34, 37, 42. Règle citée comme texte du monde, réussite : 12, 14, 38. Chute qui « va au bout sans désamorcer » : 114.
C5 R reconstituable depuis les faits (contrainte 3)	Le lecteur reconstruit ce que le texte tait (Eco ○ ; Iser ○ ; implicature chez Grice ✓ ; pertinence chez Sperber & Wilson ○). Une conséquence simplement affirmée n'offre rien à reconstruire.	« Simple affirmation », « aucune prémisse » : 6, 40, 49, 60, 74, 99. Cas limite : 102 (lien indirect, « on garde le paradoxe »).
C6 Fidélité interne de R (contrainte 6)	Le nonsense construit son propre ordre (Sewell ○, Gardner ○, Lecercle ✓) ; un ordre non tenu relève de l'absurde hors cadre, pas de l'hyperlogique.	« Règles internes pas respectées » : 21 (3a=1 à recalibrer), 5.
C7 Sens littéral, non figuré (contrainte 5)	Une métaphore se lit sans conflit de cadre (Lakoff & Johnson ○ ; Ricoeur ○). L'énoncé doit rester vrai au sens littéral.	« Simple métaphore » : 8, 17, 22, 89.
C8 Ni énigme ni vérité banale (contrainte 8)	Une énigme se résout par calcul, ce qui est une résolution au sens de D3 (Suls ○) ; un énoncé simplement vrai ou logique n'oppose rien à un cadre.	Énigmes : 26, 88, 96. Logique ou vrai : 15, 19, 62, 86.
C9 Validité par défaut (contrainte 9)	Le document admet le sophisme comme attribut (Ionesco ○ ; Gattegno ○). Sur le corpus, une erreur du narrateur se lit comme une erreur, non comme une conséquence assumée ; la cellule cible exige donc une rigueur valide (Hamblin ○ pour la typologie des sophismes).	« Sophiste », « juste faux » : 36, 48, 71, 113. Remarque sur l'erreur qui désamorce : 90.
C10 Productivité conservée, jugée insuffisante (contrainte 7)	Critère subjectif (document du 11 novembre : κ à calibrer) ; les juges LLM s'alignent mal sur les experts en création (Chakrabarty ✓) : ne pas la déléguer à un juge.	« Ne mène nulle part » : 27, 31, 37, 78. 3c=1 sans réussite : 16, 38, 42, 46, 98.
C11 Diversité : domaine tiré au sort, motifs bannis (contrainte 11)	Le RLHF réduit la diversité (Kirk ✓) ; l'homogénéité est forte entre modèles (Jiang ✓) ; elle tient à un biais de typicalité des préférences, atténuable par le prompt (Zhang ✓, verbalized sampling).	Tiroir A-E-I-O-U : 7, 37, 78, 124. Rue du Boulanger : 16, 67, 82. Surface humide : 5, 22, 48. Chat et culte : 43, 85. Alphabet en 26 s : 54, 111.

4. Prompt de génération, version 2

Cible : cellule hyperlogique créative, en monde ordinaire. Sortie en trois champs vérifiables, sans rien d'autre. {DOMAINE} est tiré au sort dans une liste d'institutions et de pratiques (état civil, copropriété, poste, école, assurance, justice, bibliothèque, etc.), à constituer sans reprendre les énoncés d'appui.

> Produis un énoncé absurde de type hyperlogique, en trois champs, dans le domaine : {DOMAINE}.
>
> **R** : une règle explicite, en une phrase, qui existe ou pourrait exister dans nos institutions, notre langue, nos procédures ou nos conventions (règlement, usage, définition, formule juridique). Pas de loi physique inventée.
>
> **N** : la norme fondamentale de sens commun que la conséquence va heurter (« on s'attendrait à ce que… »). Elle engage quelque chose qui compte (justice, identité, mort, propriété, autorité, vérité, soin), pas une simple habitude pratique.
>
> **Énoncé** : un texte court (3 à 8 phrases) où des personnes ordinaires appliquent R à la lettre, sans erreur, jusqu'à une conséquence C qui viole N.
>
> **Contraintes.** (1) Monde ordinaire : aucune magie, aucune loi physique modifiée, aucune entité ou propriété impossible (invisibilité, duplication, animal qui parle) ; n'ouvre pas de monde à part (« dans ce monde… »). (2) R et C doivent être compatibles dans ce monde ordinaire, et C résulte uniquement de l'application littérale de R. (3) R peut apparaître comme texte du monde (plaque, règlement, statuts) ; sinon le lecteur doit pouvoir la reconstituer à partir des faits. (4) Ni le narrateur ni un personnage ne commente, ne s'étonne, ne justifie ni n'explique ; pas de morale, pas de chute explicative. (5) La violation passe par un fait concret (lieu, objet, personne, chiffre), vrai au sens littéral : ni métaphore, ni analogie, ni jeu de mots. (6) R est appliquée de la même façon à chaque occurrence. (7) C permet au moins une déduction supplémentaire non triviale, que tu n'énonces pas. (8) La violation se voit sans calcul : pas d'énigme à résoudre. (9) Le passage de R à C est valide : aucune erreur de raisonnement. (10) Aucun locuteur ne tire avantage de la violation. (11) Évite les motifs déjà très fréquents : tiroirs étiquetés, noms de rue, surfaces humides, chats, alphabet récité.
>
> **Sortie** : uniquement les trois champs R, N, Énoncé. Aucun commentaire, aucune note, aucune vérification des contraintes.

Conditions de comparaison suggérées. (a) consigne nue (« écris un énoncé absurde ») ; (b) définition théorique seule ; (c) prompt v1 du 11 novembre ; (d) prompt v2 complet ; (e) ablations de v2 par groupe de contraintes : sans monde ordinaire (1), sans enjeu (N), sans interdit de commentaire (4 et sortie), sans domaine tiré au sort (11). Les ablations sont nécessaires car v2 change plusieurs choses à la fois. Variante à tester pour la diversité : demander plusieurs énoncés avec une probabilité estimée (verbalized sampling, Zhang ✓).

5. Énoncés étudiés servant de référence

Extraits tels que dans la feuille Annotation, avec le commentaire de l'annotateur. Utilisables comme jeu de calibration ou, avec précaution (risque de recopie), comme exemples dans une condition de prompt.

id	Extrait (règle ou énoncé)	Commentaire de l'annotateur	Choix éclairé
14	« Le bureau ne garde et ne remet que des objets perdus. » Mme Sorel reconnaît son parapluie, le commis tamponne « retrouvé » et le pose côté bureau. « Dehors, il pleut. »	« Il est parfait. »	C2, C3, C4 : règle réelle, enjeu humain, aucune explication
114	« Anne demanda le sel. Paul lui tendit la salière. Mais Anne, ayant prononcé « sel », dut offrir son pain en retour. »	Fonctionne : « va au bout du paradoxe sans le désamorcer »	C4
12	Toute séance s'ouvre par la lecture intégrale du compte rendu intégral de la précédente (Amicale du Vieux-Pont).	« Kafkaesque »	C2, C3
38	« le perdant, et lui seul, range les pièces » ; la nulle de 1987 reste sous une cloche à fromage.	Petit fun inattendu, mais « la formulation brise l'effet »	C4
85	Le chat lèche la soupe ; « la cuillère en bois… est portée en procession ».	Absurde par incongruité chargée de connotation ; hors cadre	Voie P ; à trancher avec C1 (le 43, très proche, est la préférée)
1	On projette un point lumineux au centre d'une absence qualifiée d'« invisible ».	« Aucun sens »	C1, C2
33	Le morceau de clé glissé sous la poule « éclot à l'aube en deux morceaux identiques ».	« + merveilleux qu'absurde »	C1
37	Tiroir « A-E-I-O-U » de Clara, suivi d'un bloc « Détails des contraintes ».	« Trop expliqué, pas de friction »	C4
71	Le collectionneur achète le musée pour douze euros « car il a trouvé une étiquette » sur un cadre.	« Sophiste »	C9
8	« La statue de marbre déborde. »	« Simplement une métaphore »	C7
26	Registre de la tour Belvédère : « 4e étage : Lina Morel, 9 ans, majeure. »	« Juste une énigme »	C8
108	Statuts exigeant le parrainage de deux membres, dont le fondateur du Cercle.	« Paradoxe banal, aucun enjeu moral »	C3

6. Références

✓ = notice consultée (document du 11 novembre) ; ○ = non consultée, à vérifier. Les années sont celles de l'édition d'origine, de mémoire pour les ○.

Référence	Usage dans la refonte	Statut
Coleridge S. T., *Biographia Literaria*, 1817	Suspension consentie de l'incrédulité : le genre suspend N (C1)	○
Todorov T., *Introduction à la littérature fantastique*, Seuil, 1970 ; Jackson R., *Fantasy: The Literature of Subversion*, Methuen, 1981	Frontière avec le merveilleux et le fantastique (C1). Chez Todorov le fantastique strict repose sur l'hésitation : nommer la catégorie exclue « hors monde ordinaire »	○
Ryan M.-L., *Possible Worlds, Artificial Intelligence and Narrative Theory*, Indiana UP, 1991 ; Lewis D., « Truth in Fiction », *American Philosophical Quarterly*, 1978	Accessibilité depuis le monde réel, écart minimal (C1)	○
Hart H. L. A., *The Concept of Law*, Oxford, 1961 ; Kripke S., *Wittgenstein on Rules and Private Language*, 1982 ; Carroll L., « What the Tortoise Said to Achilles », *Mind*, 1895	Application littérale des règles (C2)	○
Bergson H., *Le Rire*, 1900	Le mécanique plaqué sur du vivant (C2)	○
Nagel T., « The Absurd », *J. of Philosophy* 68(20), 1971	Collision entre sérieux des engagements et arbitraire possible (C3)	✓
McGraw A. P. & Warren C., « Benign Violations », *Psychological Science*, 2010 ; Brewer W. F. & Lichtenstein E. H., « Stories are to entertain », *J. of Pragmatics*, 1982	Violation d'une norme qui compte ; tension narrative et enjeu (C3)	○
Suls J. M., 1972 ; Raskin V., *Semantic Mechanisms of Humor*, 1985	Incongruité-résolution : expliquer ou résoudre désamorce (C4, C8)	○
Eco U., *Lector in fabula*, 1979 ; Iser W., *Der Akt des Lesens*, 1976 ; Sperber D. & Wilson D., *Relevance*, 1986	Le lecteur reconstruit les blancs du texte (C5)	○
Grice H. P., « Logique et conversation », *Communications* 30, 1979	Implicature, base de N et de la reconstruction (C5)	✓
Lecercle J.-J., *Philosophy of Nonsense*, Routledge, 1994 ; Sewell E., 1952 ; Gardner M., 1960	Le nonsense construit son propre ordre (C6)	✓ Lecercle ; ○ autres
Lakoff G. & Johnson M., *Metaphors We Live By*, 1980 ; Ricoeur P., *La métaphore vive*, 1975	Distinguer littéral et figuré (C7)	○
Hamblin C. L., *Fallacies*, Methuen, 1970 ; Ionesco E., *Rhinocéros*, 1959 ; Gattegno J., *Le Monde*, 1969	Typologie des sophismes ; sophisme assumé comme cellule distincte (C9)	○
Chakrabarty T. et al., « Art or Artifice? », CHI '24	Les juges LLM ne remplacent pas l'annotation experte (C10)	✓
Kirk R. et al., ICLR 2024 ; Jiang L. et al., « Artificial Hivemind », NeurIPS 2025 ; Zhang J. et al., « Verbalized Sampling », ICML 2026	Perte de diversité, homogénéité inter-modèles, atténuation par le prompt (C11)	✓
Tam Z. R. et al., « Let Me Speak Freely? A Study on the Impact of Format Restrictions on LLM Performance », 2024	Les formats imposés peuvent dégrader la production (C4) ; venue exacte à vérifier	○
Wang Y. et al., « Drivel-ology », EMNLP 2025	Jeu de calibration possible ; nonsense à profondeur, proche de la voie P (section 5, id 85)	✓

7. Points de vigilance et décisions ouvertes

- **Ids 43 et 85.** Les préférés de l'annotateur échouent au test de monde ordinaire (le 43 : crypte lunaire, moines chantant en dialecte de souris). Décider si le mécanisme de connotation chargée reste une voie P séparée, ou si le test ne vise que les lois physiques violées.
- **Sophisme.** Le document de définitions en fait un attribut, la pratique d'annotation le traite comme disqualifiant. La refonte tranche provisoirement : valide par défaut, sophisme assumé en cellule distincte.
- **Annotation.** Un seul annotateur ; des écarts internes (par exemple 3a=1 à l'id 21 malgré le commentaire). Calibrer κ par champ, en priorité 1b, 2c et la productivité.
- **Références.** Toutes les références ○ sont à vérifier avant citation ; aucune lacune de littérature NLP sur la génération d'absurde sous règle explicite n'a été confirmée par recherche.
- **Attribution.** L'exclusion du fantastique par suspension de la friction est une articulation proposée par le projet ; aucune des références ○ ne la formule telle quelle.